

DETECCIÓN DE HUSOS DURANTE EL SUEÑO EN EEG

Camila Leyva Escalante, Laura Peñaloza López y Daniel Felipe Lasso Mora

I. Formulación del problema

Cuando una persona entra en un estado de somnolencia se realiza una clasificación de las diferentes ondas eléctricas que se perciben desde electrodos ubicados en el cuero cabelludo. Esto nos permite diferenciar etapas específicas entre rangos delimitados de frecuencia y ciertos cambios presentados que pueden ser marcadores para la presencia de enfermedades como esquizofrenia, sin embargo, poder identificarlos en un electroencefalograma (EEG) es mucho más complicado si no se tiene un programa que pre procese estas ondas. En concreto, si estos cambios, más técnicamente llamados Husos no son detectados a tiempo se pueden estar pasando por alto enfermedades mentales muy graves que probablemente ya tengan un tiempo avanzadas, que con una detección temprana se hubiera podido controlar y realizar a tiempo su debido tratamiento.

Actualmente no se han encontrado investigaciones que estén avanzando sobre la presencia de estos husos en los EEG y es por esto que nos enfocamos en poder tratar la señal, para que estos “cambios” pudieran ser más visibles y así, su detección fuera más evidente, sencilla y fácil de diagnosticar para los profesionales encargados de esto.

II. Justificación

El motivo por el que quisimos realizar la investigación usando y aplicando los conocimientos de la asignatura de procesamiento digital de señales y el estudio de estas, en nuestro caso, de ECG, es detectar a partir de las frecuencias y rangos de las señales generadas en la encefalografía, enfermedades, patologías o diagnósticos para un paciente de manera temprana, ayudando al personal médico y agilizando este proceso.

III. Descripción base de datos

La base de datos utilizada para la realización de este proyecto: <https://www.kaggle.com/jbouv27/eeg> tiene la medición de un electroencefalograma principalmente en los electrodos C3-A1 y C4-A, al mismo tiempo, proporciona los datos recolectados por los electrodos O1-A1 y O2-A1.

Los datos mencionados anteriormente se agrupan en dos archivos de tipo .csv llamados “extrait_wSleepPage01.csv” y “spindles.csv” respectivamente. De estos tomamos el archivo “spindles” para detectar la presencia de Husos.

Los datos del archivo seleccionado se midieron de un solo EEG durante 12.985 segundos con 0.005s de separación entre muestras, es decir, se tienen 2597 muestras.

IV. Objetivos

Objetivo general:

Determinar la presencia de Husos como patrón de sueño en el paciente a través del electroencefalograma usado en el estudio.

Objetivos Específicos:

1. Hacer un pre-procesamiento de señales contenidas en archivos .csv mediante el lenguaje de programación python en la herramienta google colab.
2. Detectar qué ritmo cerebral predominó durante el EEG.
3. Aplicar los contenidos estudiados en la materia procesamiento digital de señales y las funciones de python trabajadas.

V. Marco teórico

El electroencefalograma, abreviado EEG, es una técnica de medición que detecta la actividad eléctrica en tiempo real que tiene el cerebro. Este es tomado mediante el uso de electrodos los cuales se fijan sobre el cuero cabelludo, capturando la forma de comunicación de las neuronas que se da a través de potenciales de acción, es decir, impulsos eléctricos que de igual manera se generan a pesar de que el individuo esté durmiendo, ya que están activas todo el tiempo.

Esta actividad es la que se manifiesta como líneas onduladas en un registro de electroencefalograma.

El origen de la señal eléctrica está en las células piramidales de la corteza cerebral, cabe aclarar que cada una de estas forman

un dipolo eléctrico el cual permite recoger y registrar una señal de la actividad eléctrica presentada en cada región cerebral amplificando la diferencia de potencial medida por los electrodos receptores de la señal que pueden estar en el cuero cabelludo (EEG estándar), en la superficie cortical (EEG cortical) o pueden ser intracerebrales (EEG de profundidad).

Siguiendo este razonamiento, un EEG es capaz de determinar cambios en la actividad cerebral, los cuales pueden ser útiles para diagnosticar trastornos cerebrales o sobre todo, en este proyecto, realizar un seguimiento de la actividad cerebral en los 4 ritmos que se han definido para su estudio.

A continuación presentamos los 4 ritmos utilizados generalmente y que a su vez dependen de la ubicación de los electrodos, la edad del paciente y específicamente en este estudio, el estado de conciencia del sujeto:

- $0.5 \leq \delta < 4.0$ Hz
- $4.0 \leq \theta < 8.0$ Hz
- $8.0 \leq \alpha < 13.0$ Hz
- $13.0 \leq \beta < 30.0$ Hz

Ritmo Delta δ :

Las ondas delta son oscilaciones, tienen una mayor amplitud de onda por esto son de bajas frecuencias. Normalmente están asociadas con etapas de sueño profundo.

En la actividad cerebral se presentan en etapas tres y cuatro, en casos de daño cerebral y coma. Las ondas delta se presentan también en sueño profundo sin soñar y no están presentes en las otras etapas del sueño (1,2 y de movimiento rápido de ojos).

También son muy habituales en los bebés y en los niños más pequeños, por lo tanto a medida que nos hacemos mayores la tendencia es a producir menos ondas de este tipo.

Ritmo theta □:

El segundo de los tipos de ritmos cerebrales se relacionan principalmente con las capacidades imaginativas, la reflexión y el sueño. Estas suelen mostrar una elevada actividad cuando experimentamos emociones muy profundas.

Ritmo alfa α:

El alfa surge en un estado intermedio donde hay tranquilidad o relajación, pero no sueño, es un estado propicio para meditar. Lo podemos experimentar también cuando estamos en el sofá viendo la tele o en la cama descansando, pero sin llegar a dormirnos.

Ritmo beta β:

Estamos ya en espectros de frecuencias más altas que surgen como resultado de una actividad neuronal intensa.

Por lo tanto son estados muy interesantes y complejos, se relacionan con esas actividades cotidianas donde ponemos mucha atención, cuando nos mantenemos alerta y necesitamos a su vez estar pendientes de múltiples actividades como conducir, realizar un examen, hacer una exposición, estar en una reunión de trabajo presentando un proyecto, entre otras.

Adicionalmente a los ritmos anteriormente mencionados, podemos

añadir el ritmo sigma que está en un rango de frecuencias entre 12 y 14 Hz. Representa una modalidad del ritmo alfa puesto que este ritmo se presenta como característica de la segunda fase del sueño sin movimientos oculares rápidos conocidos como Huso del sueño o spindles en inglés.

Principalmente son ráfagas de las frecuencias mencionadas anteriormente generadas en el tálamo y en la corteza cerebral; Por otro lado, se han investigado como posibles biomarcadores para ciertos trastornos mentales, como la esquizofrenia.

VI. Propuesta metodológica

La propuesta de solución que pretendemos plantear es enfocada en el momento de la identificación de los husos para prevenir complicaciones futuras.

Así, buscamos detectar el ritmo presente en el paciente cuando se tomó el EEG, es por esto que necesitamos hacer el pre procesamiento del archivo para poder así obtener las energías concentradas en los rangos de frecuencia de cada uno de estos.

Según la concentración de energía podemos establecer en la presencia de husos para lo cual es también necesario corroborar que el paciente sí se encontraba durmiendo cuando se hizo la medición.

Esto se hizo mediante el pre procesamiento en google colab utilizando el lenguaje de programación python. A continuación presentamos los segmentos de código utilizados.

```
import numpy as np
import pandas as pd # procesar base de datos, .CSV
import matplotlib.pyplot as plt
import scipy.fftpack
from scipy import fft #Transformada rápida de Fourier
print('Librerías cargadas...')
```

Fig. 1 Importación de librerías

Como se ve en la figura 1, el primer segmento de código se basa en la implementación de las librerías de las cuales hacemos un énfasis en pandas que nos sirve para el tratamiento de archivos .csv tal como el que trae los datos que utilizamos.

```
df = pd.read_csv('spindles.csv', delimiter = ";")
df
```

	Fecha	Horas	Minutos	Segundos	EOG Left[µV]	EEG C3-A1[µV]	EEG O1-A1[µV]	EEG C4-A1[µV]	EEG O2-A1[µV]
0	8/03/2016	1	27	21.5	-7.12890625	2.05078125	23.6328125	3.02734375	18.45703125
1	8/03/2016	1	27	21.505	-6.640625	-2.05078125	19.43359375	2.83203125	19.7265625
2	8/03/2016	1	27	21.51	-6.34765625	-1.85546875	17.28515625	4.1015625	19.3359375
3	8/03/2016	1	27	21.515	-7.32421875	-1.66015625	16.89453125	5.56640625	19.23828125
4	8/03/2016	1	27	21.52	-5.6640625	-0.48828125	16.796875	7.421875	20.99609375
...
2593	8/03/2016	1	48	3.845	-29.296875	-35.83984375	-1.7578125	-30.2734375	6.25
2594	8/03/2016	1	48	3.85	-28.41796875	-27.734375	3.515625	-23.2421875	14.0625
2595	8/03/2016	1	48	3.855	-27.44140625	-20.8984375	9.27734375	-17.3828125	16.89453125
2596	8/03/2016	1	48	3.86	-27.05078125	-16.9921875	9.765625	-11.42578125	16.9921875
2597	8/03/2016	1	48	3.865	-26.953125	-17.48046875	7.32421875	-8.69140625	13.0859375

2598 rows x 9 columns

Fig. 2 Lectura archivo

En el segundo segmento de código hacemos la lectura del archivo y también lo mostramos para corroborar la misma.

```
df['Tiempo (s)'] = np.arange(0, (2598*0.005), 0.005)
df_final = df[['Tiempo (s)', "EEG C3-A1[µV]", "EEG O1-A1[µV]", "EEG C4-A1[µV]", "EEG O2-A1[µV]"]]
df_final
```

	Tiempo (s)	EEG C3-A1[µV]	EEG O1-A1[µV]	EEG C4-A1[µV]	EEG O2-A1[µV]
0	0.000	2,05078125	23,6328125	3,02734375	18,45703125
1	0.005	-2,05078125	19,43359375	2,83203125	19,7265625
2	0.010	-1,85546875	17,28515625	4,1015625	19,3359375
3	0.015	-1,66015625	16,89453125	5,56640625	19,23828125
4	0.020	-0,48828125	16,796875	7,421875	20,99609375
...
2593	12.965	-35,83984375	-1,7578125	-30,2734375	6,25
2594	12.970	-27,734375	3,515625	-23,2421875	14,0625
2595	12.975	-20,8984375	9,27734375	-17,3828125	16,89453125
2596	12.980	-16,9921875	9,765625	-11,42578125	16,9921875
2597	12.985	-17,48046875	7,32421875	-8,69140625	13,0859375

2598 rows x 5 columns

Fig. 3 Vector de tiempo y copia

Ahora bien, es necesario la creación del vector de tiempo lo cual se puede ver en la figura 3. Observando la figura 2, hay componentes de los datos que no son necesarios, por esto, optamos por omitirlos haciendo una copia de las columnas que si son de nuestro interés.

```
cambiar = ["EEG C3-A1[µV]", "EEG O1-A1[µV]", "EEG C4-A1[µV]", "EEG O2-A1[µV]"]
for i in cambiar:
    df_final[i] = [l.replace(',','.') for i in df_final[i]]

df_final = df_final.astype('float')
```

df_final

0	0.000	2.050781	23.632812	3.027344	18.457031
1	0.005	-2.050781	19.433594	2.832031	19.726562
2	0.010	-1.855469	17.285156	4.101562	19.335938
3	0.015	-1.660156	16.894531	5.566406	19.238281
4	0.020	-0.488281	16.796875	7.421875	20.996094
...
2593	12.965	-35.839844	-1.757812	-30.273438	6.250000
2594	12.970	-27.734375	3.515625	-23.242188	14.062500
2595	12.975	-20.898438	9.277344	-17.382812	16.894531
2596	12.980	-16.992188	9.765625	-11.425781	16.992188
2597	12.985	-17.480469	7.324219	-8.691406	13.085938

2598 rows x 5 columns

Fig. 4 Conversión tipo de dato

En la figura 3, se puede ver que en la copia, los datos tienen coma en lugar de puntos señalando el inicio de los decimales, por lo que no son de tipo numérico, por esto, decidimos hacer una conversión de las comas por puntos y establecimos que estos datos ahora son de tipo float.

```
fig, axs = plt.subplots(4, sharex=True, sharey=True)
fig.set_size_inches(9, 12)
labels = ["EEG C3-A1[µV]", "EEG O1-A1[µV]", "EEG C4-A1[µV]", "EEG O2-A1[µV]"]
colors = ["g", "r", "c", "k"]
fig.suptitle('Gráficas EEG de spindles')

for i, ax in enumerate(axs):
    axs[i].plot(df_final['Tiempo (s)', df_final[labels[i]], color=colors[i], label=labels[i])
    axs[i].legend(loc='upper right')

plt.xlabel('Tiempo (s)')
plt.show()
```

Fig. 5 Código para graficar en función del tiempo

En la figura 5 se muestra las líneas de código necesarias para poder generar las gráficas de la figura 6.




Fig. 6 Gráficas en función del tiempo.

```
df2 = df_final.copy()
df2 = df2-np.mean(df2)
labels = ["EEG C3-A1[uV]", "EEG O1-A1[uV]", "EEG C4-A1[uV]", "EEG O2-A1[uV]"]
df2 = df2[labels].apply(fft)

Fs = 200
t = np.linspace(0,(len(df2)-1)/Fs, len(df2)-1, endpoint = False)

Espec= 2.0 / len(t) * np.abs( df2[labels] [ 0:int(len(t)/2) ] )
Freq = np.linspace(0.0, Fs/2 , int(len(t)/2) )

fig, axs = plt.subplots(4, sharex=False, sharey=False)
fig.set_size_inches(9, 12)
colors = ["g","r","c","k"]
fig.suptitle('Espectros del EEG ')

for i,ax in enumerate(axs):
    axs[i].plot(Freq, Espec[labels[i]], color=colors[i], label=labels[i])
    axs[i].legend(loc="upper center")
    axs[i].grid()

plt.xlabel('Frecuencia (Hz)')
plt.show()
```

Fig. 7 Código para generar y graficar el espectro de la señal

La figura 7 implementa las líneas que permiten generar el espectro de la señal EEG tratada, para que posteriormente este sea graficado como se aprecia en la figura 8.

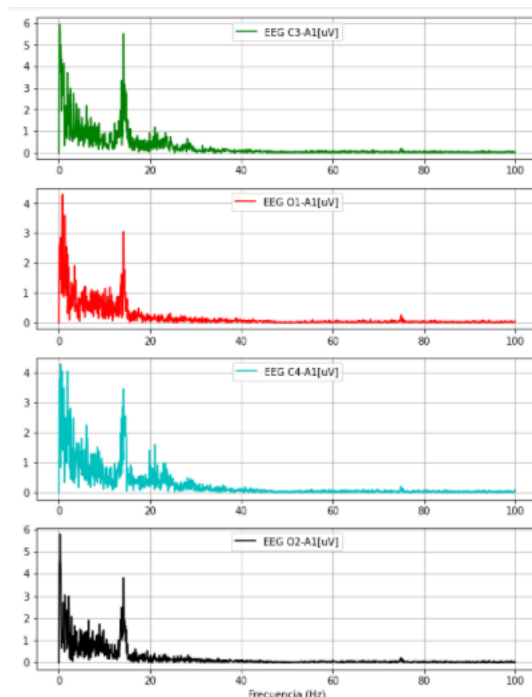


Fig. 8 Espectro de la señal.

De los espectros obtenidos es necesario conocer la energía concentrada en los rangos de frecuencia de los ritmos expuestos en el marco teórico, debido a esto, el espectro que se trabajó con data frames debe ser convertido a un vector por cada columna que este tenía.

```
[ ] C3_A1=Espec["EEG C3-A1[uV]"].to_numpy()
    O1_A1=Espec["EEG O1-A1[uV]"].to_numpy()
    C4_A1=Espec["EEG C4-A1[uV]"].to_numpy()
    O2_A1=Espec["EEG O2-A1[uV]"].to_numpy()
```

Fig. 9 Conversión del espectro a vectores

Luego, para poder conocer las energías de cada ritmo es necesario establecer los rangos de frecuencia de cada uno de estos, aclarando que el orden de los resultados de energía concentrada en cada electrodo se da en el siguiente orden:

1. EEG C3-A1[uV]
2. EEG O1-A1[uV]
3. EEG C4-A1[uV]
4. EEG O2-A1[uV]

```

▶ Edelta = [0,0,0,0]
for i in range(len(Freq)):
    if Freq[i] >= 0.5:
        if Freq[i] < 4:
            Edelta[0] = (Edelta[0] + C3_A1[i])/3.5
            Edelta[1] = (Edelta[1] + O1_A1[i])/3.5
            Edelta[2] = (Edelta[2] + C4_A1[i])/3.5
            Edelta[3] = (Edelta[3] + O2_A1[i])/3.5

for j in range(len(Edelta)):
    print(j+1,".",Edelta[j])

```

```

1 . 0.3930529058489629
2 . 0.22503788981871284
3 . 0.6117907187175786
4 . 0.30563838167595725

```

Fig. 10 Energía delta

```

▶ Ebeta = [0,0,0,0]
for i in range(len(Freq)):
    if Freq[i] >= 13:
        if Freq[i] < 30:
            Ebeta[0] = (Ebeta[0] + C3_A1[i])/17
            Ebeta[1] = (Ebeta[1] + O1_A1[i])/17
            Ebeta[2] = (Ebeta[2] + C4_A1[i])/17
            Ebeta[3] = (Ebeta[3] + O2_A1[i])/17

for j in range(len(Ebeta)):
    print(j+1,".",Ebeta[j])

```

```

1 . 0.009960633666967424
2 . 0.010004044073256174
3 . 0.0073564832181821655
4 . 0.009269404297241915

```

Fig. 13 Energía beta

```

[19] Etheta = [0,0,0,0]
for i in range(len(Freq)):
    if Freq[i] >= 4:
        if Freq[i] < 8:
            Etheta[0] = (Etheta[0] + C3_A1[i])/4
            Etheta[1] = (Etheta[1] + O1_A1[i])/4
            Etheta[2] = (Etheta[2] + C4_A1[i])/4
            Etheta[3] = (Etheta[3] + O2_A1[i])/4

for j in range(len(Etheta)):
    print(j+1,".",Etheta[j])

```

```

1 . 0.3167999453559453
2 . 0.1813756069553248
3 . 0.31204099204274816
4 . 0.19656283725863047

```

Fig. 11 Energía theta

```

[22] Esigma = [0,0,0,0]
for i in range(len(Freq)):
    if Freq[i] >= 12:
        if Freq[i] < 14:
            Esigma[0] = (Esigma[0] + C3_A1[i])/2
            Esigma[1] = (Esigma[1] + O1_A1[i])/2
            Esigma[2] = (Esigma[2] + C4_A1[i])/2
            Esigma[3] = (Esigma[3] + O2_A1[i])/2

for j in range(len(Esigma)):
    print(j+1,".",Esigma[j])

```

```

1 . 1.5768654746454274
2 . 0.6319629624455227
3 . 1.4926859613140673
4 . 1.3594461665500819

```

Fig. 14 Energía sigma

```

[20] Ealfa = [0,0,0,0]
for i in range(len(Freq)):
    if Freq[i] >= 8:
        if Freq[i] < 13:
            Ealfa[0] = (Ealfa[0] + C3_A1[i])/5
            Ealfa[1] = (Ealfa[1] + O1_A1[i])/5
            Ealfa[2] = (Ealfa[2] + C4_A1[i])/5
            Ealfa[3] = (Ealfa[3] + O2_A1[i])/5

for j in range(len(Ealfa)):
    print(j+1,".",Ealfa[j])

```

```

1 . 0.24771052672184726
2 . 0.16269420088873937
3 . 0.17815186479060557
4 . 0.19709178384302423

```

Fig. 12 Energía alfa

Una vez realizado todo el proceso descrito anteriormente, encontramos que el paciente se encontraba durmiendo puesto que los ritmos delta y theta son los que más energía poseen.

Como se ve en la figura 14 la energía sigma es la más concentrada en todos los electrodos, es decir, si hay presencia de Husos por lo que el paciente deberá tener un chequeo más especializado.

VII. Referencias

[1] Mayo Clinic. (2020, Abril 15). EEG (electroencefalograma). [En línea]. Disponible en: [EEG \(electroencefalograma\) - Mayo Clinic](https://www.mayoclinic.org/es-es/symptoms-and-conditions/brain-activity/eeeg/symptoms-and-causes/symptoms-and-causes)

[2] Anón. (2021, Mayo 19). Ondas delta. [En línea]. Disponible en: [Ondas delta - Wikipedia, la enciclopedia libre](#)

[3] La Mente es Maravillosa Revista sobre psicología, filosofía y reflexiones sobre la vida. (s.f). Tipos de ondas cerebrales: Delta, Theta, Alfa, Beta y Gamma. [En línea]. Disponible en: [Tipos de ondas cerebrales: Delta, Theta, Alfa, Beta y Gamma - La Mente es Maravillosa](#)

[4] Morales, G. (s.f). Técnicas básicas de electroencefalografía: principios y aplicaciones clínicas. [En línea]. Disponible en: [Técnicas básicas de electroencefalografía: principios y aplicaciones clínicas \(isciii.es\)](#)

[5] Anón. (2021, Febrero 18). Fases del sueño. [En línea]. Disponible en: [Fases del sueño - Wikipedia, la enciclopedia libre](#)

[6] Anón. (s.f). Husos del sueño (Spindles). [En línea]. Disponible en: [Husos del sueño \(Spindles\) \(psiquiatria.com\)](#)

[7] Delgado, A. “Análisis del electroencefalograma con transformada de Fourier y modelos paramétricos”. Ingeniería eléctrica (s.f).